

week10 출석과제

☼ Status	Not started
----------	-------------

5.0 토큰화 개요

자연어와 자연어 처리

- 자연어: 사람들이 쓰는 언어 활동을 위해 자연히 만들어진 언어
- 자연어 처리: 컴퓨터가 인간의 언어를 이해하고 해석 및 생성하기 위한 기술

토큰화

- 자연어 처리 모델을 만들기 위해 말뭉치를 토큰으로 나뉘어야 함
- 토큰나이저 구축 방법: 공백 분할, 정규표현식 적용, 어휘 사전 적용, 머신러닝 활용
 - 시스템의 성능/처리 결과에 큰 영향을 주기도 함

5.1 단어 및 글자 토큰화

단어 토큰화

- 텍스트 데이터를 의미 있는 단위인 단어로 분리하는 작업
- 자연어 처리 분야에서 핵심적인 전처리 작업
- `split` 메서드로 문자열을 나눔

글자 토큰화

- 글자 단위로 문장을 나누는 방식
- 장점: 비교적 작은 단어 사전을 구축할 수 있음

5.2 형태소 토큰화

형태소 토큰화

- 텍스트를 형태소 단위로 나누는 토큰화 방법
- 언어의 문법과 구조를 고려해 단어를 분리하고 이를 의미있는 단위로 분류
- 교착어인 언어에서 중요하게 수행(한국어 포함)
- 형태소: 실제로 의미를 가지고 있는 최소의 단위

형태소 어휘 사전

- 자연어 처리에서 사용되는 단어의 집합인 어휘사전
 - 그 중 각 단어의 형태소 정보를 포함하는 사전
- 단어가 어떤 형태소들의 조합으로 이루어져 있는지에 대한 정보 담음
- 품사 태깅

KoNLPy

- 한국어 자연어 처리를 위해 개발된 라이브러리
- 명사 추출, 형태소 분석, 품사 태깅 등
- Okt: 문장을 입력 받아 명사, 구, 형태소, 품사 등의 정보 추출하는 메서드 제공
- 꼬꼬마: 명사, 문장, 형태소, 품사 추출
- 라이브러리: 동일한 메서드라도 분석기에 따라 다른 결과

NLTK

- 자연어 처리를 위해 개발된 라이브러리
- 주로 영어 자연어 처리를 위해 개발

spaCy

- 사이션을 기반으로 개발된 오픈 소스 라이브러리
- 자연어 처리를 위한 기능
- 빠른 속도와 높은 정확도를 목표로 하는 머신 러닝 기반의 자연어 처리 라이브러리

5.3 하위 단어 토큰화

BPE

- 절차: 문자 단위 시작 → 가장 자주 출현하는 인접 쌍 병합 반복
- 산출물: 병합 규칙 + 어휘
- 특징: 빈도 기반, 간단/효율적, 신어 일반화 강함

토큰라이저 학습 공통 프로세스

1. 데이터 수집: 도메인 대표성/크기/클린
2. 정규화: lowercasing, NFD/NFKC, 특수문자 규칙
3. 프리토큰화: 공백/ByteLevel/Metaspace
4. 모델 학습: BPE/WordPiece/Unigram, vocab 크기 결정
5. 포스트프로세싱: CLS/SEP 삽입 등 템플릿 처리
6. 평가: 토큰 길이, 커버리지, OOV, Perplexity 대리 지표
7. 저장/배포: 버전 고정, 재현성/효환성 체크

WordPiece

- 목표: BERT 개열에서 채택. 확률기반 최대우도 기준으로 어휘 선정
- 차이점: BPE는 빈도 기반 병합, WordPiece는 언어모델 우도/점수를 사용
- 접두사: 보통 ##로 서브워드 표기(단어 중간)
- 모델 학습 과정
 1. 코퍼스 수집/정제

2. 정규화 규칙 확정
3. 프리토큰화
4. WordPiece 학습
5. 포스트프로세싱
6. 품질평가
7. 버전관리 및 배포

6 임베딩

텍스트 벡터화

- 텍스트를 숫자로 변환하는 과정
- 원-핫 인코딩
- 빈도 벡터화

워드 임베딩

- 단어를 고정된 길이의 실수 벡터로 표현하는 방법
- 단어의 의미를 벡터 공간에서 다른 단어와의 상대적 위치로 표현해 단어 간의 관계 추론
- Word2Vec, fastText

언어모델

- 입력된 문장으로 각 문장을 생성할 수 있는 확률을 계산하는 모델
- 주어진 문장을 바탕으로 문맥을 이해하고, 문장 구성에 대한 예측 수행
- 자기회귀 언어 모델: 입력된 문장들의 조건부 확률을 이용해 다음에 올 단어를 예측
 - 각 시점에서 다음에 올 토큰 예측이 중요
- 통계적 언어 모델

- 언어의 통계적 구조를 이용해 문장이나 단어의 시퀀스를 생성/분석
- 마르코프 체인으로 구현

N-gram

- 가장 기초적인 통계적 언어 모델
- 텍스트에서 N개의 연속된 단어 시퀀스를 하나의 단어로 취급
→ 특정 단어 시퀀스가 등장할 확률 추정

TF-IDF

- 텍스트 문서에서 특정 단어의 중요도를 계산하는 방법
- 문서 내에서 단어의 중요도를 평가하는 데 사용되는 통계적 가중치
- BoW: 문서나 문장을 단어의 집합으로 표현
- 단어 빈도: 문서 내에서 특정 단어의 빈도수
- 문서 빈도: 한 단어가 얼마나 많은 문서에 나타나는지
- 역문서 빈도: 문서 내에서 특정 단어가 얼마나 중요한지
- TF-IDF: 문서 빈도 * 역문서 빈도